

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



MÔN MÁY HỌC
ỨNG DỤNG MACHINE LEARNING TRONG DỰ
ĐOÁN TỶ LỆ CHUYỂN ĐỔI KHÁCH HÀNG TRÊN BỘ
DỮ LIỆU LEAD SCORING

GVHD: Võ Nguyễn Lê Duy

Nhóm sinh viên thực hiện: Nhóm 6

MSSV	Họ và Tên
23520824	Võ Anh Kiệt
23520825	Võ Anh Kiệt
23520816	Phạm Anh Kiệt
23520845	Lê Xuân Song Lĩnh
23520878	Lê Quang Long

MỤC LỤC

1.	GIỚI THIỆU BÀI TOÁN	4
1.1	Bối cảnh và động lực nguyên cứu	4
1.2	Mục tiêu nguyên cứu và bộ dữ liệu	4
2.	LÀM SẠCH DỮ LIỆU.....	4
2.1	Loại bỏ các cột không phù hợp.....	4
2.2	Xử lý dữ liệu thiếu.....	4
2.3	Loại bỏ bản ghi trùng.....	5
3.	KHÁM PHÁ DỮ LIỆU (EDA) VÀ XỬ LÝ OUTLIERS.....	5
3.1	Phân tích đơn biến	5
3.1.1	Phân tích biến định lượng	5
3.1.2	Phân tích biến mục tiêu và phân loại	5
3.2	Phân tích đa biến	6
3.2.1	Phân tích Persona (Nghề nghiệp x Chuyên ngành).....	6
3.2.2	Phân tích nguồn Lead & hành vi Website.....	6
3.2.3	Phân tích tương tác (Engagement Analysis)	6
3.3	Phân tích outlier.....	6
3.3.1	Xử lý Outlier cho dữ liệu số.....	6
3.3.2	Xử lý Outlier cho dữ liệu danh mục.....	7
4.	FEATURE ENGINEERING VÀ FEATURE SELECTION.....	7
4.1	Feature Engineering.....	7
4.1.1	Đặc trưng đa thức	7
4.1.2	Đặc trưng thủ công.....	7
4.2	Feature Selection	8
4.2.1	Quy trình lựa chọn đa tầng	8
4.2.2	Danh sách đặc trưng cuối cùng	8
5.	PHƯƠNG PHÁP THỰC HIỆN	9
5.1	Mô hình máy học	9
5.1.1	Mô hình Logistic Regression	9
5.1.2	Mô hình Support Vector Machine (SVM)	9
5.1.3	Mô hình XGBoost.....	9

CS114.Q22 – MÁY HỌC

5.1.4	Mô hình LightGBM	9
5.1.5	Mô hình RandomForest	9
5.2	Mô hình tối ưu tham số	10
5.2.1	GridSearchCV	10
5.2.2	Optuna	10
5.3	Bộ tham số của mô hình sau khi tuning.....	10
5.3.1	GridSearchCV	10
5.3.2	Optuna	11
6.	ĐỘ ĐO VÀ KẾT QUẢ ĐÁNH GIÁ.....	11
6.1	Giới thiệu độ đo.....	11
6.1.1	Accuracy	12
6.1.2	Precision.....	12
6.1.3	Recall	12
6.1.4	F1 Score	12
6.2	Kết quả đánh giá.....	12
6.2.1	GridSeachCV với 5 mô hình máy học	12
6.2.2	Optuna với 5 mô hình máy học.....	12
7.	NHẬN XÉT VÀ HƯỚNG PHÁT TRIỂN	13

1. GIỚI THIỆU BÀI TOÁN

1.1 Bối cảnh và động lực nguyên cứu

Thị trường giáo dục trực tuyến ngày càng cạnh tranh khốc liệt. X Education, đơn vị cung cấp các khóa học cho người đi làm, thu hút lượng lớn khách hàng tiềm năng (leads). Tuy nhiên, tỷ lệ chuyển đổi thực tế chỉ đạt 30%. Tỷ lệ chuyển đổi thấp này dẫn đến sự phân bổ nguồn lực không hiệu quả, khiến đội ngũ Sales bị quá tải do phải chăm sóc khách hàng dàn trải, gây lãng phí lớn về thời gian và chi phí vận hành.

Động lực cốt lõi của nghiên cứu này là ứng dụng các thuật toán Học máy (Machine Learning) để giải quyết vấn đề phân loại và ưu tiên khách hàng tiềm năng.

1.2 Mục tiêu nguyên cứu và bộ dữ liệu

Mục tiêu chính của đề tài là xây dựng mô hình Lead Scoring (Chấm điểm Khách hàng Tiềm năng) nhằm:

- **Dự đoán khả năng chuyển đổi (Converted):** Biến mục tiêu là Converted (1: đã chuyển đổi, 0: chưa chuyển đổi).
- **Xác định các yếu tố ảnh hưởng:** Tìm ra các đặc trưng, hành vi và kênh tiếp cận then chốt quyết định kết quả chuyển đổi.

Bộ dữ liệu Lead Scoring của X Education bao gồm khoảng 9.000 mẫu. Dữ liệu chứa các thuộc tính liên quan đến nguồn khách hàng, hành vi truy cập website, hoạt động tương tác, thông tin nghề nghiệp và chất lượng khách hàng tiềm năng.

2. LÀM SẠCH DỮ LIỆU

Mục tiêu của bước này là đưa dữ liệu thô (ban đầu có 9.240 dòng và 37 cột) về dạng ổn định hơn trước khi huấn luyện mô hình.

2.1 Loại bỏ các cột không phù hợp

Nhóm đã loại bỏ ba nhóm cột chính:

- **Cột định danh:** Loại bỏ các cột như Prospect ID và Lead Number vì chúng chỉ dùng để nhận diện từng lead và không mang ý nghĩa dự đoán cho mô hình.
- **Cột có nhiều Missing Value hoặc ít thông tin:** Loại bỏ các cột có quá nhiều giá trị khuyết hoặc khó khai thác ổn định (ví dụ: Asymmetrique Profile Index, Lead Quality, Country).
- **Cột có phương sai thấp:** Loại bỏ các cột gần như chỉ nhận một giá trị áp đảo, ít đóng góp vào việc phân loại (ví dụ: Search, Magazine, Digital Advertisement, và các cột liên quan đến thông báo cập nhật khóa học).

2.2 Xử lý dữ liệu thiếu

Sau khi loại bỏ các cột không cần thiết, dữ liệu được xử lý missing value theo kiểu dữ liệu:

- **Biến phân loại:** Điền giá trị thiếu bằng "Unknown" thay vì xóa dòng để giữ lại thông tin rằng dữ liệu bị thiếu. Các cột áp dụng bao gồm What is your current occupation, Specialization, City, Last Activity, Lead Source, Tags, và Lead Profile.

- **Biến số:** Điền missing value bằng Median (TotalVisits, Page Views Per Visit). Median được ưu tiên vì ít bị ảnh hưởng bởi các giá trị cực đoan (outlier) hơn giá trị Mean.

2.3 Loại bỏ bản ghi trùng

Mặc dù dữ liệu gốc không có dòng trùng hoàn toàn, sau khi loại bỏ các cột định danh và giảm chiều dữ liệu, một số dòng trở nên giống nhau về mặt đặc trưng. Nhóm đã sử dụng `drop_duplicates()` để loại bỏ các bản ghi trùng này.

→ Kết quả sau làm sạch: Dữ liệu còn lại **7.690 dòng** và **16 cột**, không còn missing value.

3. KHÁM PHÁ DỮ LIỆU (EDA) VÀ XỬ LÝ OUTLIERS.

Phân tích Dữ liệu Khám phá được thực hiện nhằm hiểu rõ cấu trúc dữ liệu, xác định các đặc trưng quan trọng và tìm ra mối liên hệ giữa các biến với mục tiêu chuyển đổi.

3.1 Phân tích đơn biến

3.1.1 Phân tích biến định lượng

Chỉ tiêu	TotalVisits	Total Time Spent on Website	Page Views Per Visit
Trung vị (Q2)	3,0	349	2,33
Trung bình	4,13	686,73	2,83

Thời gian truy cập (Total Time Spent on Website): Khách hàng chuyển đổi thường ở lại website lâu hơn, cho thấy đây là một yếu tố phản ánh mức độ quan tâm sâu sắc.

Hành vi truy cập: Phần lớn khách hàng truy cập từ 2 đến 6 lần và xem từ 2 đến 4 trang mỗi lần truy cập. Sự hiện diện của các giá trị outlier trong TotalVisits và Page Views Per Visit cần được xử lý để tránh làm sai lệch mô hình.

3.1.2 Phân tích biến mục tiêu và phân loại

Tỷ lệ chuyển đổi tổng thể: Biến mục tiêu Converted có tỷ lệ chuyển đổi $\approx 39,2\%$ ($3.018/7.690$) và tỷ lệ không chuyển đổi là $\approx 60,8\%$, cho thấy dữ liệu hơi mất cân bằng.

Tags: Đây là biến có sức mạnh phân biệt mạnh mẽ nhất.

- Tags tích cực (Conversion Rate > 96%): Will revert after reading the email (96,6%), Closed by Horizzon (99,4%), Lost to EINS (97,6%).
- Tags tiêu cực (Conversion Rate < 3%): Already a student (0,8%), Ringing (3,0%), Not doing further education (0,7%).

Thông tin hoạt động: Biến Last Activity cung cấp thông tin chi tiết hơn Last Notable Activity, do đó nên được ưu tiên sử dụng trong phân tích sâu.

3.2 Phân tích đa biến

3.2.1 Phân tích Persona (Nghề nghiệp x Chuyên ngành)

Nhóm ưu tiên: Working Professional (Người đi làm) có tỷ lệ chuyển đổi cao nhất ở hầu hết các chuyên ngành, nhiều nhóm đạt trên 90%. Điều này phản ánh nhu cầu học tập rõ ràng, khả năng tài chính tốt và động lực phục vụ sự nghiệp.

Nhóm rủi ro: Nhóm Unknown có tỷ lệ chuyển đổi thấp rõ rệt (chỉ 10% đến 20%), chứng tỏ đây là các leads kém chất lượng do thiếu thông tin.

Nhóm tiềm năng: Nhóm Unemployed có tỷ lệ chuyển đổi ở mức trung bình (36% đến 60%), cần có chiến lược tiếp cận phù hợp để nhấn mạnh cơ hội nghề nghiệp.

3.2.2 Phân tích nguồn Lead & hành vi Website

Tầm quan trọng của Thời gian: Total Time Spent on Website là một tín hiệu quan trọng phản ánh mức độ quan tâm của lead. Lead ở lại website lâu hơn thường có xu hướng chuyển đổi nhiều hơn.

Hiệu quả Kênh: Kênh Google cho kết quả tốt hơn Direct Traffic.

- Conversion Rate của Google đạt 39.94%.
- Conversion Rate của Direct Traffic là 32.17%.
- Lead từ Google cũng có thời gian ở lại website trung bình cao hơn.

3.2.3 Phân tích tương tác (Engagement Analysis)

Chuỗi hành vi vàng: Chuỗi hành vi SMS Sent -> SMS Sent được xác định là một "golden sequence" với tỷ lệ chuyển đổi rất cao (66.24%) trên 1.810 leads. Đây là tín hiệu rất mạnh cho khả năng chuyển đổi.

Ảnh hưởng của Ưu đãi (Tài liệu miễn phí): Việc nhận tài liệu miễn phí (A free copy of Mastering The Interview) giúp tăng engagement (thời gian ở lại website cao hơn) nhưng lại giảm conversion rate. Nhóm nhận tài liệu đạt 36.68% chuyển đổi, thấp hơn nhóm không nhận là 42.16%.

3.3 Phân tích outlier

3.3.1 Xử lý Outlier cho dữ liệu số

Nhóm đã sử dụng Thuật toán IQR (Interquartile Range) để nhận diện và xử lý các giá trị ngoại lai.

Phương pháp giới hạn: Các giá trị nằm ngoài khoảng $[Q1 - 1.5 * IQR ; Q3 + 1.5 * IQR]$ sẽ bị gán lại về giá trị cận dưới (lower) hoặc cận trên (upper).

Biến số	Số lượng Outliers	Giới hạn trên (Upper Bound)	Nhận xét
TotalVisits	467 mẫu (~6.1%)	9.6	Biểu đồ lệch trái, outlier trải đều về phía bên phải.

Page Views Per Visit	211 mẫu (~2.7%)	7.0	Biểu đồ lệch trái, outlier tập trung ở phía trên.
Total Time Spent on Website	0 mẫu	2462.6	Không có outlier do biên độ IQR rất lớn.

3.3.2 Xử lý Outlier cho dữ liệu danh mục

Các giá trị có tần suất $< 1.0\%$ được xem là outlier và cần được gộp lại thành nhóm "Other" hoặc "Not Specified" để giảm nhiễu và tăng cường khả năng học của mô hình đối với các nhóm có ý nghĩa thống kê.

Ví dụ thực hiện:

- **Lead Origin:** Gộp Quick Add Form và Lead Import (tần suất $< 1\%$) thành Other.
- **Lead Source:** Gộp các nguồn truy cập nhỏ (ví dụ: Facebook, bing, Click2call) thành Other, đồng thời chuẩn hóa tên gọi (ví dụ: Google + google thành Google).
- **Tags:** Gộp các nhãn có liên quan về ý nghĩa (ví dụ: gộp các tag thể hiện ý định phản hồi sau như Still thinking, Interested in Next batch thành Will Revert) hoặc gộp các nhãn phản ánh vấn đề liên hệ (ví dụ: wrong number given, opp hangup thành invalid number).

4. FEATURE ENGINEERING VÀ FEATURE SELECTION

4.1 Feature Engineering

Mục tiêu của bước này là tạo ra các đặc trưng mới có khả năng dự đoán cao hơn các đặc trưng thô ban đầu, bao gồm Đặc trưng Đa thức (tương tác) và Đặc trưng Thủ công (tổng hợp).

4.1.1 Đặc trưng đa thức

Sử dụng lớp PolynomialFeatures để tạo ra các đặc trưng tương tác phi tuyến giữa ba biến hành vi chính là Total Time Spent on Website, Page Views Per Visit, và TotalVisits.

Các đặc trưng tương tác chính được tạo ra:

- **ttspow_pvps:** Tương tác giữa Total Time Spent on Website và Page Views Per Visit.
- **pmps_totalvisits:** Tương tác giữa Page Views Per Visit và TotalVisits.
- **tttspow_totalvisits:** đặc trưng tương tác giữa **Total Time Spent on Website** và **TotalVisits**.

4.1.2 Đặc trưng thủ công

Nhóm đã xây dựng các đặc trưng thể hiện mức độ tương tác và chất lượng của lead:

- **Time_Per_Page:** Thời gian trung bình dành cho mỗi trang, phản ánh mức độ quan tâm chi tiết đến nội dung. Công thức:

$$Time_Per_Page = \frac{\text{Total Time Spent on Website}}{\text{Page Views Per Visit} + 1}$$

- **Time_Per_Visit:** Thời gian trung bình dành cho mỗi lần truy cập. Công thức:

$$Time_Per_Visit = \frac{\text{Total Time Spent on Website}}{\text{Total Visits} + 1}$$

- **Engagement Score:** Đặc trưng tổng hợp mức độ tương tác. Đặc trưng này kết hợp có trọng số giữa TotalVisits (0.2), Page Views Per Visit (0.2), và Total Time Spent on Website (0.6), trong đó thời gian truy cập được ưu tiên trọng số cao hơn.

4.2 Feature Selection

Nhóm đã áp dụng quy trình lựa chọn đa tầng (Multi-stage Selection) kết hợp ba phương pháp Filter, Embedded và Wrapper để tìm ra tập đặc trưng tối ưu.

4.2.1 Quy trình lựa chọn đa tầng

1. **Low Variance Filter (Filter):** Loại bỏ các đặc trưng có phương sai thấp (ví dụ: Do Not Call).
2. **Mutual Information (MI) & Multicollinearity (Filter):** Tính điểm MI để đo mối quan hệ phi tuyến với biến mục tiêu. Kiểm tra ma trận tương quan (ngưỡng $r > 0.7$) để loại bỏ các đặc trưng bị đa cộng tuyến. Trong trường hợp đa cộng tuyến, đặc trưng có điểm MI thấp hơn sẽ bị loại. Bước này đã loại bỏ 8 đặc trưng dư thừa, giữ lại 12 đặc trưng.
3. **GBM Importance (Embedded):** Sử dụng mô hình Gradient Boosting để tính toán tầm quan trọng của đặc trưng. Giữ lại các đặc trưng có độ quan trọng cao hơn 0.6 lần giá trị trung bình. Bước này giảm số lượng đặc trưng xuống còn 6.
4. **RFECV (Wrapper):** Sử dụng kỹ thuật Recursive Feature Elimination with Cross-Validation (sử dụng Random Forest) để xác nhận số lượng đặc trưng tối ưu là 6.

4.2.2 Danh sách đặc trưng cuối cùng

Sau quá trình sàng lọc nghiêm ngặt, 6 đặc trưng quan trọng nhất được giữ lại để huấn luyện mô hình bao gồm:

1. Engagement_Score (Đặc trưng tổng hợp quan trọng nhất).
2. Lead Origin.
3. Last Activity.
4. What is your current occupation.
5. Lead Profile.
6. pvps_totalvisits (Đặc trưng tương tác).

Việc giảm số chiều dữ liệu xuống còn 6 đặc trưng đã được kiểm chứng bằng Cross-validation, cho thấy mô hình vẫn duy trì được độ chính xác cao (ví dụ: Gradient Boosting đạt AUC (Test Set) là 0.8989).

5. PHƯƠNG PHÁP THỰC HIỆN

5.1 Mô hình máy học

5.1.1 Mô hình Logistic Regression

Logistic Regression là một thuật toán Machine Learning phổ biến dùng cho bài toán phân loại nhị phân. Trong bài toán Lead Scoring, mô hình được sử dụng để dự đoán khả năng một khách hàng tiềm năng có chuyển đổi thành khách hàng thực tế hay không.

Logistic Regression có ưu điểm là: dễ triển khai, tốc độ huấn luyện nhanh, dễ giải thích kết quả, phù hợp với bài toán phân loại nhị phân và có thể xuất ra xác suất chuyển đổi của từng khách hàng.

5.1.2 Mô hình Support Vector Machine (SVM)

SVM, viết tắt của Support Vector Machine, là một thuật toán Machine Learning thường được sử dụng cho bài toán phân loại. Trong bài toán Lead Scoring, SVM được dùng để phân loại khách hàng tiềm năng thành hai nhóm: có khả năng chuyển đổi và không có khả năng chuyển đổi.

SVM có ưu điểm là: hoạt động tốt với dữ liệu có ranh giới phân lớp rõ ràng, hỗ trợ nhiều dạng kernel khác nhau, có khả năng xử lý quan hệ phi tuyến thông qua kernel RBF và phù hợp với bài toán phân loại nhị phân.

5.1.3 Mô hình XGBoost

XGBoost, viết tắt của Extreme Gradient Boosting, là một thuật toán Machine Learning thuộc nhóm Boosting Tree. Mô hình này xây dựng nhiều cây quyết định theo cách tuần tự, trong đó các cây sau sẽ học để sửa lỗi cho các cây trước.

XGBoost được tối ưu để: Huấn luyện nhanh, cho độ chính xác cao, hạn chế overfitting tốt, xử lý dữ liệu dạng bảng hiệu quả, phù hợp với bài toán phân loại nhị phân.

5.1.4 Mô hình LightGBM

LightGBM, viết tắt của Light Gradient Boosting Machine, là một thuật toán thuộc nhóm Gradient Boosting Decision Tree. LightGBM cũng xây dựng nhiều cây quyết định theo cơ chế boosting, nhưng được tối ưu để huấn luyện nhanh và sử dụng bộ nhớ hiệu quả.

LightGBM được tối ưu để: Huấn luyện nhanh, dùng ít bộ nhớ hơn, vẫn duy trì độ chính xác cao, scale tốt với dữ liệu lớn, hoạt động tốt trên dữ liệu dạng bảng.

5.1.5 Mô hình Random Forest

Random Forest là một thuật toán Machine Learning thuộc nhóm Ensemble Learning. Mô hình này kết hợp nhiều cây quyết định để đưa ra dự đoán chính xác và ổn định hơn so với một cây quyết định đơn lẻ. Mỗi cây trong Random Forest được huấn luyện trên một phần dữ liệu và một phần đặc trưng được chọn ngẫu nhiên. Sau đó, kết quả của nhiều cây được tổng hợp lại để đưa ra dự đoán cuối cùng.

Random Forest có một số ưu điểm: Dễ triển khai, hoạt động ổn định, ít bị overfitting hơn Decision Tree đơn lẻ, có thể xử lý quan hệ phi tuyến, phù hợp làm mô hình so sánh với các mô hình boosting.

5.2 Mô hình tối ưu tham số

5.2.1 GridSearchCV

Grid Search là phương pháp dùng để tìm bộ hyperparameter cho mô hình machine learning bằng cách. Nó thử tất cả các tổ hợp tham số có thể, đánh giá hiệu năng từng tổ hợp và chọn ra tham số tối ưu. Đây là một trong những kỹ thuật phổ biến nhất trong quá trình hyperparameter tuning.

Quy trình tối ưu bằng GridSearchCV được thực hiện như sau:

- Xây dựng estimator cho từng mô hình.
- Trong mỗi trial, GridSearchCV đề xuất một bộ tham số cho mô hình.
- Mô hình được huấn luyện và đánh giá bằng cross-validation.
- Metric dùng để đánh giá là f1.
- Sau nhiều lần thử nghiệm, GridSearch chọn ra bộ tham số cho kết quả tốt nhất.

5.2.2 Optuna

Optuna là một thư viện dùng để tự động tối ưu siêu tham số cho mô hình machine learning. Thay vì thử toàn bộ các tổ hợp tham số như Grid Search, Optuna sử dụng chiến lược tìm kiếm thông minh để ưu tiên thử các vùng tham số có khả năng cho kết quả tốt hơn.

Quy trình tối ưu bằng Optuna được thực hiện như sau:

- Xây dựng một hàm objective.
- Trong mỗi trial, Optuna đề xuất một bộ tham số cho mô hình.
- Mô hình được huấn luyện và đánh giá bằng cross-validation.
- Metric dùng để đánh giá là ROC-AUC.
- Sau nhiều lần thử nghiệm, Optuna chọn ra bộ tham số cho kết quả tốt nhất.

5.3 Bộ tham số của mô hình sau khi tuning

5.3.1 GridSearchCV

Thuật toán	Bộ tham số
Logistic Regression	<code>{'C': 10, 'penalty': 'l1', 'solver': 'liblinear'}</code>
SVM	<code>{'C': 10, 'gamma': 'auto', 'kernel': 'rbf'}</code>
XGBoost	<code>{'colsample_bytree': 0.8, 'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 100, 'subsample': 0.8}</code>
LightGBM	<code>{'learning_rate': 0.1, 'max_depth': -1, 'n_estimators': 100, 'num_leaves': 31, 'subsample': 0.8}</code>

Random Forest	{ 'max_depth': 10, 'min_samples_leaf': 2, 'min_samples_split': 2, 'n_estimators': 100 }
---------------	---

5.3.2 Optuna

Thuật toán	Bộ tham số
Logistic Regression	{ 'C': 0.33687006016020793, 'solver': 'liblinear', 'penalty': 'l2', 'max_iter': 100, 'random_state': 42 }
SVM	{ 'kernel': 'rbf', 'C': 19.16466784634673, 'gamma': 0.03766626973386321 }
XGBoost	{ "n_estimators": 203, "max_depth": 3, "learning_rate": 0.13096700386160283, "subsample": 0.9718780969166109, "colsample_bytree": 0.9098686146196069, "colsample_bylevel": 0.8864477761213812, "min_child_weight": 1, "gamma": 0.9399664462694064, "reg_alpha": 2.3870291967286637e-08, "reg_lambda": 1.8013031961826498e-06, "scale_pos_weight": 1.6681074486089229 }
LightGBM	{ "n_estimators": 686, "max_depth": 3, "num_leaves": 118, "learning_rate": 0.09163373390468887, "min_child_samples": 7, "subsample": 0.9676012277392844, "subsample_freq": 7, "colsample_bytree": 0.747461212124191, "reg_alpha": 0.001960117388921266, "reg_lambda": 4.6170094124846734e-06, "min_split_gain": 0.3319096817832968 }
Random Forest	{ "n_estimators": 499, "max_depth": 8, "max_features": "log2", "min_samples_split": 11, "min_samples_leaf": 1, "max_samples": 0.6734913812723163 }

6. ĐỘ ĐO VÀ KẾT QUẢ ĐÁNH GIÁ

6.1 Giới thiệu độ đo

Kết quả dự đoán so với thực tế sẽ chia làm 4 trường hợp:

- TP (True Positive): Thực tế đúng, mô hình đoán đúng.
- TN (True Negative): Thực tế sai, mô hình đoán sai (đ đoán là Không).
- FP (False Positive): Thực tế sai, nhưng mô hình đoán nhầm là Đúng (Dương tính giả).

CS114.Q22 – MÁY HỌC

- FN (False Negative): Thực tế đúng, nhưng mô hình đoán nhầm là Không (Âm tính giả).

6.1.1 Accuracy

Accuracy là tỷ lệ dự đoán đúng trên tổng số mẫu dữ liệu. Nó cho biết mô hình dự đoán chính xác bao nhiêu phần trăm toàn bộ dữ liệu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

6.1.2 Precision

Trong số những mẫu mà mô hình đoán là Đúng, thì thực tế có bao nhiêu mẫu thực sự Đúng?

$$Precision = \frac{TP}{TP + FP}$$

6.1.3 Recall

Trong số tất cả những mẫu thực tế là Đúng, mô hình đã tìm ra được bao nhiêu mẫu?

$$Recall = \frac{TP}{TP + FN}$$

6.1.4 F1 Score

F1-Score chính là trung bình điều hòa (harmonic mean) giữa Precision và Recall, giúp bạn có một cái nhìn cân bằng nhất khi cả hai độ đo trên đều quan trọng.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

6.2 Kết quả đánh giá

6.2.1 GridSearchCV với 5 mô hình máy học

	Logistic Regression	SVM	XGBoost	LightGBM	Random Forest
F1	0.6825	0.7760	0.7774	0.7671	0.776
Accuracy	0.7718	0.8134	0.8283	0.8192	0.8277
Recall	0.6346	0.8256	0.7894	0.7736	0.79
Precision	0.7446	0.7320	0.7658	0.7736	0.7625

6.2.2 Optuna với 5 mô hình máy học

	Logistic Regression	SVM	XGBoost	LightGBM	Random Forest
--	---------------------	-----	---------	----------	---------------

F1	0.76	0.81	0.8133	0.8203	0.8202
Accuracy	0.77	0.82	0.8244	0.8290	0.8296
Recall	0.75	0.80	0.8095	0.8198	0.8185
Precision	0.77	0.81	0.8185	0.8208	0.8222

7. NHẬN XÉT VÀ HƯỚNG PHÁT TRIỂN

Nghiên cứu đã ứng dụng thành công các thuật toán Học máy (Machine Learning) trên bộ dữ liệu Lead Scoring của X Education để dự đoán khả năng chuyển đổi của khách hàng tiềm năng. Mô hình đạt độ chính xác ổn định ở mức xấp xỉ 80%.

Hướng phát triển tiếp theo:

- Tối ưu hóa và làm giàu dữ liệu.
- Thử nghiệm các kiến trúc mô hình nâng cao.
- Đưa mô hình vào thực tế